

ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas



Informe Técnico

Proyecto de 1er Bimestre

Asignatura: Recuperación de Información

Integrantes:

Danny Constante

Alexander Paillacho

Andrés Pérez

Docente: Prof. Iván Carrera

Fecha de entrega: 01 de junio de 2026

1. Descripción del Corpus Utilizado

El corpus utilizado corresponde al dataset Reuters Financial News, obtenido mediante la API de Kaggle (identificador: thedevastator/uncovering-financial-insights-with-the-reuters-2). Este dataset es una colección de noticias financieras de la agencia Reuters, distribuidas en múltiples archivos CSV que representan distintas particiones históricas del corpus original (ModApte, ModHayes, ModLewis, entre otras).

Tras el proceso de ingesta, saneamiento y eliminación de documentos nulos o de longitud inferior a 30 caracteres, el corpus consolidado comprende 51,000 documentos aproximadamente, distribuidos en ocho archivos CSV. Cada documento fue enriquecido con un identificador único (doc_id), un campo de trazabilidad de origen (csv_origen) y un campo de título cuando estaba disponible en los metadatos originales.

2. Decisiones de Diseño

2.1 Arquitectura de Pipeline Bifurcado

La decisión de diseño más relevante del sistema es la implementación de un pipeline de preprocesamiento bifurcado, implementado en el módulo limpieza.py. Esta decisión parte de la premisa de que los modelos estadísticos clásicos y los modelos neuronales basados en Transformers tienen requerimientos de entrada fundamentalmente distintos.

Para los modelos léxicos (Jaccard, TF-IDF, BM25), el texto es sometido a normalización a minúsculas, eliminación de caracteres no alfabéticos, tokenización, remoción de stopwords del inglés más un conjunto personalizado de términos de alta frecuencia del dominio financiero (pct, mln, dlrs, said, reuters, entre otros) y lematización mediante WordNetLemmatizer de NLTK. Este proceso reduce la dimensionalidad del vocabulario y mejora la precisión de las coincidencias léxicas al colapsar variantes morfológicas.

Para el modelo semántico (Sentence-Transformers con FAISS), se aplica únicamente una sanitización superficial: eliminación de etiquetas HTML residuales, URLs y caracteres de control ASCII. La gramática, conjugación verbal y conectores lógicos se preservan intactos, ya que el mecanismo de auto-atención del modelo Transformer requiere la estructura sintáctica completa para inferir el significado contextual de cada token.

2.2 Implementación de Modelos Clásicos

Los tres modelos clásicos fueron implementados de forma propia, sin recurrir a bibliotecas de alto nivel que abstraigan la lógica de recuperación:

- **Jaccard:** implementado sobre conjuntos de tokens lematizados. La similitud se calcula como el cociente entre la intersección y la unión de los conjuntos de términos de la consulta y el documento. Se aplica una optimización mediante el índice invertido para extraer únicamente los documentos candidatos que comparten al menos un término con la consulta, evitando la comparación secuencial sobre los 51,000 documentos.
- **TF-IDF + Coseno:** se utiliza TfidfVectorizer de scikit-learn con suavizado logarítmico (sublinear_tf=True), poda de términos con min_df=2 y max_df=0.95. La similitud coseno se calcula mediante álgebra lineal matricial. El motor de búsqueda que proyecta la consulta al espacio vectorial y recupera los documentos más similares fue implementado de forma propia.

- **BM25:** implementación propia del modelo probabilístico Okapi BM25 con hiperparámetros estándar de la literatura académica ($k_1=1.5$, $b=0.75$). El IDF probabilístico de Robertson-Sparck Jones se pre-calcula una única vez sobre el vocabulario completo antes de habilitar el buscador, optimizando el tiempo de respuesta durante la búsqueda interactiva. La normalización por longitud de documento se aplica en cada consulta utilizando la longitud promedio del corpus como referencia.

2.3 Recuperación Semántica con FAISS

Se seleccionó el modelo all-mpnet-base-v2 de la biblioteca sentence-transformers como encoder semántico. Este modelo genera embeddings de 768 dimensiones y es reconocido en el estado del arte como uno de los encoders de oraciones de propósito general con mayor precisión semántica disponibles públicamente.

Los embeddings se almacenan en un índice FAISS de tipo IndexFlatIP (producto interno plano). La elección de este tipo de índice responde a que, al normalizar los vectores a magnitud $L_2=1$ (parámetro `normalize_embeddings=True`), el producto interno es matemáticamente equivalente a la similitud coseno. Esto permite obtener la máxima precisión geométrica aprovechando la velocidad de cómputo de la biblioteca FAISS implementada en C++. Se descartó el uso de índices aproximados (como IVF o HNSW) porque el volumen del corpus (51,000 documentos) es manejable en memoria sin sacrificar exactitud.

2.4 Interfaz CLI y Enrutamiento de Consultas

La interfaz de usuario se implementó como una clase BuscadorCLI con arquitectura de máquina de estados finitos. Un bucle externo gestiona nuevas sesiones de búsqueda, mientras un bucle interno mantiene en memoria el conjunto de resultados para permitir la paginación sin recalculiar los vectores. El enrutamiento de consultas garantiza que cada modelo recibe el formato de entrada que requiere: texto crudo para los modelos léxicos (que aplican su propia lematización interna) y texto con sanitización superficial para el modelo semántico.

2.5 Evaluación con Pooling Estratificado

En proyectos con corpus de gran escala, la construcción de un conjunto de relevancia (qrels) mediante anotación humana es inviable. Con 51,000 documentos y cinco consultas de prueba, la revisión manual de todos los documentos candidatos excedería cualquier marco temporal razonable. Por esta razón, el sistema adopta la técnica de pooling estratificado, estándar en las evaluaciones de la conferencia TREC (Text REtrieval Conference).

El ground truth se construye de la siguiente manera: para cada consulta, se recuperan los top-10 documentos de cada uno de los cuatro modelos y se forma la unión de todos ellos como conjunto de documentos relevantes. Este enfoque es equitativo porque incluye al modelo semántico en la construcción del pool, evitando la creación de una cámara de eco léxica que penalizaría injustamente a la recuperación densa cuando esta encuentra documentos contextualmente válidos sin coincidencia exacta de palabras. Las métricas calculadas (Precision@K, Recall@K, AP y MAP) son válidas dentro de los límites del conjunto de evaluación generado.

3. Ejemplos de Consultas y Resultados

Se diseñó una batería de cinco consultas estratificadas en tres categorías para estresar las fortalezas y debilidades de cada arquitectura de recuperación:

3.1 Entidades Nombradas y Vocabulario Específico del Dominio

Consultas: "Triton Energy Corp acquisition" y "OPEC crude production quota".

Resultado observado: Los modelos BM25 y TF-IDF producen los resultados más precisos para este tipo de consultas. Al tratarse de términos técnicos y nombres propios con baja frecuencia en el corpus (alta IDF), ambos modelos asignan pesos discriminativos elevados y recuperan documentos con alta concentración temática. El modelo semántico produce resultados comparables dado que los términos técnicos del dominio financiero tienen representaciones densas bien definidas en el espacio de embeddings. Jaccard muestra el rendimiento más bajo, al ignorar la rareza de los términos y ponderar igualmente la coincidencia de cualquier token.

3.2 Abstracción Semántica y Sinonimia

Consultas: "worldwide petroleum costs decrease" y "farming grain shortage problems".

Resultado observado: Este grupo de consultas evidencia la principal limitación de los modelos léxicos. Al buscar con vocabulario alternativo al utilizado en los documentos del corpus (por ejemplo, petroleum en lugar de oil, decrease en lugar de drop o fall), los modelos BM25, TF-IDF y Jaccard presentan una caída significativa en la calidad de los resultados. El modelo semántico mantiene un rendimiento estable porque proyecta tanto la consulta como los documentos al mismo espacio de significados, siendo insensible al vocabulario específico utilizado. Este fenómeno se conoce en la literatura como vocabulary mismatch problem.

3.3 Consulta de Cola Larga

Consulta: "negative impacts of the financial market crash".

Resultado observado: Ante consultas largas con múltiples tokens de alta frecuencia en el dominio financiero, BM25 demuestra su ventaja sobre TF-IDF gracias al mecanismo de saturación de frecuencia (parámetro k_1) y la normalización por longitud de documento (parámetro b). El modelo semántico produce resultados coherentes temáticamente pero con mayor dispersión espacial en el análisis PCA, lo que indica que en consultas muy genéricas el espacio de recuperación se amplía. Jaccard presenta el rendimiento más bajo por su incapacidad para ponderar la importancia relativa de cada término.

4. Análisis de Métricas de Evaluación

4.1 Metodología de Evaluación

La evaluación cuantitativa se realizó sobre las cinco consultas de la batería de prueba utilizando un pool de profundidad $K=25$ (top-25 documentos recuperados por modelo). El ground truth (documentos relevantes) se construyó dinámicamente uniendo los aportes de los cuatro modelos. Las métricas calculadas son Precision@25 (cuántos de los 25 documentos recuperados pertenecen al pool), Recall@25 (qué fracción del total del pool se logró recuperar), Average Precision@25 (AP, que penaliza el orden de aparición) y el Mean Average Precision global (MAP). Para la evaluación geométrica, se utilizó Análisis de Componentes Principales (PCA), reteniendo un 14.91% de la varianza estructural en un plano 2D.

4.2 Análisis Cuantitativo: Precisión, Recall y AP

Los resultados del sistema arrojaron un ranking global (MAP) liderado por TF-IDF (0.5912), seguido por BM25 (0.5361), Jaccard (0.4534) y el Modelo Semántico (0.4331). Al desglosar la Tabla de Métricas por consulta, se evidencian los siguientes comportamientos:

1. Dominio Léxico en Entidades Nombradas: En la consulta "OPEC crude production quota", BM25 alcanzó su pico de rendimiento con un sobresaliente AP@25 de 0.6685 y una Precision@25 de 0.7600 (19 de sus 25 documentos devueltos eran relevantes). TF-IDF lo siguió de cerca (AP 0.6356). Esto confirma que, ante jerga técnica y entidades específicas, los pesos estadísticos locales (IDF) son imbatibles.
2. Comportamiento del Recall: Es importante notar que el Recall@25 está matemáticamente limitado por el tamaño del pool. Por ejemplo, en la consulta "farming grain shortage problems", el pool totalizó 40 documentos relevantes. El máximo Recall posible era 25/40 (0.625). TF-IDF logró un Recall de 0.4250 y una precisión de 0.6800, demostrando una excelente capacidad de recuperación exhaustiva frente a BM25 (Recall 0.2500) en esta consulta específica de cola larga.
3. El Castigo al Modelo Semántico: A lo largo de las 5 consultas, el Modelo Semántico mantuvo una Precision@25 estancada en el rango de 0.4000 a 0.5200. Esto provoca que su Recall y su AP sean consistentemente los más bajos.

4.3 La Paradoja de la Varianza (PCA) vs. el Sesgo de Pooling

Si observamos exclusivamente la tabla de métricas clásicas, se concluiría erróneamente que el Modelo Semántico fracasó. Sin embargo, al cruzar la métrica de Precisión (AP) con el análisis cualitativo de Varianza Espacial (PCA), se descubre el hallazgo central de este proyecto.

El caso más crítico ocurre en la consulta de sinonimia "worldwide petroleum costs decrease":

- Métrica Cuantitativa: TF-IDF obtiene un AP muy superior (0.5289) frente al Modelo Semántico (0.4000). Jaccard: Consistente con la teoría, presentó el rendimiento más deficiente (MAP 0.45) debido a su naturaleza binaria y su incapacidad para ponderar estadísticamente la relevancia inversa (IDF) de los términos en el corpus.
- Métrica Espacial (PCA): TF-IDF presenta una dispersión altísima (Varianza Total de 0.0300), mientras que el Modelo Semántico exhibe una cohesión casi perfecta (Varianza Total de 0.0004).

TF-IDF recuperó documentos esparcidos por distintas áreas del mapa (alta varianza) simplemente porque contenían palabras sueltas como "worldwide" o "costs", pero fuera del contexto petrolero (baja cohesión temática). Por otro lado, el Modelo Semántico entendió el concepto global y agrupó 25 noticias exactas sobre la caída del valor del crudo (cohesión perfecta).

Sin embargo, debido a la metodología de Pooling (3 contra 1), la "Lista Maestra" de evaluación se sobresaturó con los documentos léxicos aportados por BM25, TF-IDF y Jaccard (los tres buscan coincidencias de caracteres). Cuando el Modelo Semántico aportó sus documentos contextualmente correctos (pero sin las palabras exactas), el sistema de evaluación los etiquetó como "Irrelevantes", hundiendo matemáticamente su Precisión, su Recall y su AP.

4.4 Conclusiones Arquitectónicas

A partir de la triangulación de resultados, se establecen las siguientes conclusiones para el ecosistema de Recuperación de Información:

1. TF-IDF y BM25 son indiscutiblemente superiores ($MAP > 0.53$) en escenarios de periodismo financiero donde la coincidencia exacta de siglas institucionales es el requerimiento principal. Conocen la estadística local del corpus de Reuters a la perfección.
2. Jaccard sirve exclusivamente como una línea base (baseline) inferior ($MAP 0.45$), ya que su naturaleza binaria no logra discriminar la rareza de los términos.
3. El Modelo Semántico (Transformer + FAISS), a pesar de obtener el MAP más bajo (0.43) por el sesgo inherente del Pooling y su naturaleza Zero-Shot (dilución de nombres propios), es cualitativamente el único motor capaz de resolver el problema del Vocabulary Mismatch. Su varianza espacial casi nula garantiza la recuperación por contexto abstracto.

La conclusión final de este diseño demuestra que la coincidencia léxica pura y la inferencia contextual exhiben comportamientos ortogonales (cubren carencias mutuamente excluyentes). Esto justifica matemáticamente el estándar actual de la industria: la implementación de motores de búsqueda Híbridos, donde la precisión estadística de BM25 se fusiona con la cohesión semántica de las redes neuronales.